



Protótipo de Assistente Virtual Baseado em RAG para Consulta às Normas da UFPI: Um Estudo de Caso

Aluno: Guilherme Torres Melo
Orientador: Armando Soares Sousa

12 de Dezembro de 2025

Departamento de Computação – Universidade Federal do Piauí (UFPI) Teresina – PI – Brasil

Sumário

1. Introdução	6. Metodologia	11. Resultados
2. Problemas da pesquisa	7. Arquitetura da Solução	12. Discussão e Conclusão
3. Objetivos	8. O “cérebro” do Agente	13. Trabalhos Futuros
4. Fundamentação Teórica	9. Engenharia de dados	14. Referências
5. Trabalhos Relacionados	10. Evolução Técnica	15. Agradecimentos



Introdução

A gestão acadêmica nas Instituições de Ensino Superior (IES) segue um conjunto de normas que orientam toda a vida universitária.

Apesar de essencial, ela é extensa e usa linguagem jurídica complexa, o que dificulta sua compreensão.

Com o avanço dos Grandes Modelos de Linguagem, tornou-se possível criar assistentes conversacionais mais naturais. Porém, usar ferramentas genéricas como o ChatGPT diretamente para interpretar normas da UFPI traz um problema central: a ocorrência de “alucinações”.



RESOLUÇÃO Nº 177/2012, DO CEPEX/UFPI


REGULAMENTO GERAL DA GRADUAÇÃO

Atualizado em 03 de maio de 2023

PRÓ-REITORIA DE ENSINO DE GRADUAÇÃO - PREG

Problemas da pesquisa

- O problema central reside na **difículdade de conciliar a necessidade de respostas rápidas com a complexidade dos documentos oficiais**. Os métodos atuais falham em dois extremos: **a consulta manual é ineficiente pela barreira da linguagem técnica, enquanto os modelos de IA genéricos, embora acessíveis, carecem de confiabilidade factual**.
- Diante desse cenário, surge a indagação fundamental que orienta este trabalho: **Como desenvolver um assistente virtual capaz de interpretar a linguagem natural dos estudantes** e retornar informações precisas da Norma 177/2012, superando tanto a dificuldade de navegação quanto o risco de alucinações?
- A resposta para essa questão é essencial para criar uma solução que **combine eficiência na recuperação da informação com o rigor normativo necessário, evitando erros interpretativos e fortalecendo a segurança** no uso de assistentes virtuais no ambiente acadêmico.



Objetivos

- O objetivo principal é desenvolver um assistente virtual capaz de interpretar a **linguagem natural** dos estudantes e **fornecer respostas precisas** com base na Norma 177/2012.
- O assistente deve ser capaz de realizar **buscas eficientes no documento oficial**, superando a necessidade de o usuário conhecer termos técnicos ou localizar manualmente informações em PDFs.
- Ao mitigar o risco de alucinações comuns em modelos generativos, busca-se garantir confiabilidade factual e agilizar o acesso dos alunos às normas acadêmicas, **reduzindo dúvidas recorrentes e a sobrecarga das coordenações de curso**.



Fundamentação Teórica



A Base Tecnológica

- Arquitetura Transformer: Permite que o modelo analise o contexto global do texto simultaneamente (Mecanismo de Atenção), superando modelos anteriores.

O Funcionamento dos LLMs

- Natureza Probabilística: Grandes Modelos de Linguagem não recuperam fatos; eles prevêm estatisticamente a próxima palavra mais provável.

O Problema Crítico

- Alucinações: A natureza estatística leva à geração de respostas fluentes e convincentes, porém factualmente falsas.
- Conclusão: O uso direto de LLMs é inviável para normas onde a precisão é obrigatória.

Embeddings e Significado

- Conversão de textos em vetores numéricos multidimensionais.
- Captura do significado semântico: termos com sentidos semelhantes ficam geometricamente próximos (Ex: "Manutenção", "Conserto").

A Vantagem da Busca Semântica

- Supera a limitação da busca por palavras-chave exatas (Ctrl+F).
- Permite encontrar o trecho correto da norma mesmo que o aluno não saiba a terminologia técnica específica (Ex: perguntar sobre "nota final" e o sistema encontrar "Média Aritmética").

Métrica de Relevância

- Similaridade de Cosseno: Cálculo matemático usado para medir a relevância entre a pergunta e os artigos da norma.
- Foca na direção dos vetores (conteúdo) e ignora a magnitude (tamanho do texto).

Fundamentação Teórica



A Lógica "Prova com Consulta" [Lewis et al., 2020]

- Em vez de confiar na "memória" do modelo (que pode falhar), o RAG obriga a IA a consultar a Norma 177/2012 antes de responder.
- Transforma o modelo de um "criador" para um "leitor e interpretador".


Como Funciona (Fluxo Simplificado)

1. Recuperação (Retrieval): O usuário pergunta -> O sistema busca os artigos exatos no documento oficial.
2. Geração (Generation): O sistema envia ao LLM: A Pergunta + Os Artigos Encontrados.


O Mecanismo de Segurança (Grounding)

- O modelo recebe uma instrução estrita: "Use APENAS o texto fornecido para responder."
- Se a resposta não estiver nos artigos recuperados, o sistema assume que não sabe, eliminando a invenção de regras (Alucinação).

Indexing



Generating



Trabalhos Relacionados




Contexto Acadêmico [Silveira Júnior, 2023]

- O Trabalho: Chatbot RAG para o regimento da UFPel usando GPT-3.5. Validou que RAG funciona para normas universitárias.
- Limitação Identificada: Dificuldade em lidar com perguntas ambíguas usando busca padrão.
- Nosso Diferencial: Implementação de Busca Vetorial Exata (Exact kNN) e filtros de metadados para resolver a ambiguidade e garantir precisão.

Otimização de Recuperação [Setty et al., 2024]

- O Trabalho: Estudo em documentos financeiros demonstrando que o gargalo do RAG não é o modelo (LLM), mas a qualidade da recuperação (Retrieval).
- A Premissa: A busca aproximada (padrão de mercado) gera erros em domínios críticos.
- Nosso Diferencial: Aplicação dessa premissa ao domínio da UFPI, substituindo índices aproximados por varredura sequencial para eliminar falsos negativos.



Metodologia



Caracterização: Pesquisa Exploratória e Aplicada | Corpus: Norma 177/2012 (UFPI).

Fase 1: Preparação (Golden Dataset)

- Criação de um gabarito ("Ground Truth") com 20 pares de perguntas e respostas.
- Baseado em dúvidas reais das coordenações (Ex: Matrícula, Frequência, Jubilação).
- Objetivo: Servir de régua para medir a precisão do sistema.


Fase 2: Desenvolvimento e Seleção

- Testes iterativos com modelos: GPT-4o-mini, Gemini 2.5 e GPT-5-mini.
- Critério de Escolha: Melhor equilíbrio entre custo e capacidade de raciocínio.
- Modelo Final (V2): GPT-5-mini (devido à estabilidade contra alucinações).

Fase 3: Validação com Usuários

- Design Intra-sujeitos: O mesmo participante realiza o teste nos dois cenários para comparação direta.
- Amostra: 10 discentes de Ciência da Computação.
- Protocolo: Responder 5 questões complexas usando o PDF Oficial vs. Chatbot.
- Métricas: Taxa de Acerto (Eficácia) e Tempo de Resposta (Eficiência).

Arquitetura da Solução




Arquitetura de Microsserviços:

- Frontend: Streamlit (Interface e Streaming).
- Backend: FastAPI (Orquestração e Endpoints REST).
- Banco: Supabase + pgvector (Armazenamento Vetorial e Estrutural).

Interface do Usuário (Destaques):

- Renderização via Streaming (resposta em tempo real).
- Feedback Integrado (Human-in-the-loop).
- Transparência com visualização de Tool Calls (auditoria do raciocínio).

Arquitetura da Solução



O "Cérebro" do Agente





Orquestração via LangGraph

- A lógica não é uma linha reta (cadeia linear), mas um Grafo Cíclico de Estados.
- Permite loops de raciocínio: o agente pode tentar buscar, falhar, refinar a busca e tentar de novo antes de responder.

O Fluxo de Decisão

1. Nó do Modelo: O GPT-5-mini analisa a pergunta e decide o próximo passo.
2. Uso de Ferramentas: O agente escolhe entre Busca Semântica (conceitos) ou Filtro de Metadados (artigos específicos).
3. Síntese: O modelo recebe os dados e gera a resposta final ancorada (grounded).





Do PDF ao Vetor: Preservando a Estrutura

- A extração de texto bruto destrói o sentido da norma.
- Solução: Conversão do PDF para Markdown. Isso preserva a hierarquia visual (Títulos, Capítulos, Seções).

Estratégia de Chunking Híbrido

- Não cortamos o texto por número de caracteres aleatórios.
- Unidade Atômica: O Artigo. Cada vetor representa um artigo completo da norma.
- Enriquecimento: Cada pedaço (chunk) carrega consigo o nome do Capítulo e da Seção a que pertence, garantindo que o modelo entenda o contexto mesmo recuperando um artigo isolado.

Armazenamento Híbrido (Supabase)

- Banco de dados relacional + vetorial (pgvector).
- Permite consultas mistas: Buscar por significado ("reprovação") E filtrar por estrutura ("apenas no Capítulo de Avaliação").

Engenharia de Dados



TÍTULO VI - DOS COMPONENTES CURRICULARES

(**Nível 1:** O tema macro)

└─── CAPÍTULO IV - DAS ATIVIDADES ACADÊMICAS ESPECÍFICAS

(**Nível 2:** A divisão temática dentro do Título)

└─── Seção IV - Do Estágio Obrigatório

(**Nível 3:** O processo específico dentro do Capítulo)

└─── Subseção II - Da Organização Administrativa Dos Estágios...

(**Nível 4:** O detalhamento operacional dentro da Seção)

└─── Art. 68. O estágio curricular obrigatório, para a sua regularidade, envolve:

(**Nível 5:** A norma jurídica/regra base)

└─── I – Coordenadoria de Estágio Obrigatório (CEO/PREG);

(**Nível 6:** Inciso - Elementos listados no artigo, usa algarismos romanos)

└─── § 1º A Coordenadoria de Estágio Obrigatório (CEO/PREG) tem como atribuições básicas:

(**Nível 7:** Parágrafo - Desdobramento ou exceção da regra)

└─── a) viabilizar as condições necessárias ao desenvolvimento do estágio obrigatório na UFPI;

(**Nível 8:** Alínea - Lista detalhada dentro de um parágrafo ou inciso, usa letras minúsculas)

Evolução Técnica



O Problema da V1:

- Busca Vetorial Aproximada (ANN/IVFFlat) gerava "falsos negativos" (não encontrava artigos existentes).
- Ferramenta única causava confusão no modelo.

A Solução na V2:

- Separação de Tools: Busca Semântica vs. Busca de Metadados (Filtro Exato).
- Mudança de Algoritmo: Transição para Busca Exata (kNN).
 - Por que? Para $N \approx 400$ artigos, a varredura sequencial é rápida e garante Recall de 100%.

Resultado (Tabela V1 vs V2):

- Salto de 60% para 100% na Taxa de Acerto.
- Eliminação total de Alucinações (0%).

Evolução Técnica



	MODELO BASE			MODELO V2
LLM	GPT 4o-mini	Gemini 2.5-flash	GPT 5-mini	GPT 5-mini
Temp	5	5	1	1
1	Acertou	Acertou	Acertou	Acertou
2	Acertou	Errou	Acertou	Acertou
3	Não Achou	Não Achou	Acertou	Acertou
4	Errou	Não Achou	Não Achou	Acertou
5	Não Achou	Não Achou	Não Achou	Acertou
6	Não Achou	Não Achou	Não Achou	Acertou
7	Errou	Não Achou	Não Achou	Acertou
8	Acertou	Acertou	Acertou	Acertou
9	Acertou	Acertou	Acertou	Acertou
10	Acertou	Acertou	Acertou	Acertou
11	Incompleta	Não Achou	Não Achou	Acertou
12	Não Achou	Não Achou	Não Achou	Acertou
13	Acertou	Acertou	Acertou	Acertou
14	Acertou	Acertou	Acertou	Acertou
15	Acertou	Acertou	Acertou	Acertou
16	Acertou	Acertou	Acertou	Acertou
17	Errou	Acertou	Incompleta	Acertou
18	Errou	Errou	Não Achou	Acertou
19	Acertou	Acertou	Acertou	Acertou
20	Acertou	Não Achou	Acertou	Acertou

Resultados: Experimento com Usuários



Comparativo de Eficiência (Tempo Médio)

- Método Manual (PDF): ~120 segundos (2 minutos) por questão.
- Dificuldade: Leitura extensa, busca por palavras-chave falha.
- Chatbot (Agentic RAG): ~30 segundos por questão.
- Resultado: Ganho de eficiência de 400% (Redução drástica da carga cognitiva).

Métrica de Confiabilidade

- Acurácia Percebida: 98% (49 de 50 interações foram úteis e corretas).
- Feedback do Usuário: "O assistente conseguiu responder de maneira satisfatória... com fundamentação e o artigo da norma."



Resultados: Experimento com Usuários



Análise do "Falso Negativo" (O erro de 2%)

- Houve apenas 1 relato de erro em 50 testes.
- Investigação: O Chatbot respondeu corretamente (Art. 118), mas o aluno confundiu o conceito de "Nota do Exame" com "Média Final".
- Conclusão: O sistema manteve o rigor técnico mesmo quando o usuário estava confuso.

Feedback de Experiência do Usuário (UX)

- Ponto de Atrito: A exibição transparente dos logs de raciocínio (Tool Calls) gerou poluição visual.
- Lição Aprendida: Para usuários finais, a transparência excessiva atrapalha. Futuras versões devem ocultar o backend (processamento) e mostrar apenas a resposta final.

Validação da Hipótese

- A transição para Busca Exata (V2) foi determinante: Zero alucinações observadas durante o experimento.

Discussão e Conclusão



Objetivo Alcançado

- O desenvolvimento do assistente baseado em Agentic RAG atingiu o objetivo de democratizar o acesso à Norma 177/2012, oferecendo uma interface amigável sem renunciar ao rigor jurídico.

Principal Contribuição Técnica

- O estudo provou que a alucinação em LLMs pode ser controlada via Engenharia de Software.
- A combinação de Busca Vetorial Exata (kNN) + Segmentação Semântica (Artigos) + Modelo "Honesto" (GPT-5-mini) foi a chave para garantir 100% de precisão nos testes de engenharia.

Impacto Prático

- Validação da viabilidade técnica para suporte acadêmico: Redução de 2 minutos para 30 segundos por consulta, com alta aprovação dos discentes.

Trabalhos Futuros



Evolução da Experiência (UX)

- Ocultar os logs técnicos (Tool Calls) da interface final para reduzir a carga cognitiva do usuário (focando apenas na resposta).

Expansão da Base de Conhecimento

- Inclusão de novos regulamentos no banco vetorial, como o Regimento Geral da UFPI e resoluções de Pós-Graduação.

Integração Sistêmica (SIGAA)

- Conectar o assistente à API do sistema acadêmico para permitir respostas personalizadas (Ex: "Eu posso me formar este ano?" cruzando a norma com o histórico escolar do aluno).

Referências



ADAMOPOULOU, E.; MOUSSIADES, L. An overview of chatbot technology. In: IFIP International Conference on Artificial Intelligence Applications and Innovations. Springer, 2020. p. 373–383.

ALMEIDA, F.; XEXÉO, G. Word embeddings: A survey. arXiv preprint arXiv:1901.09069, 2019.

ALTMAN, N. S. An introduction to kernel and nearest-neighbor nonparametric regression. The American Statistician, v. 46, n. 3, p. 175–185, 1992.

BAI, Y. et al. Constitutional AI: Harmlessness from AI feedback. arXiv preprint arXiv:2212.08073, 2022

BENTLEY, J. L. Multidimensional binary search trees used for associative searching. Communications of the ACM, v. 18, n. 9, p. 509–517, 1975.

BRASIL. Lei nº 13.709, de 14 de agosto de 2018 (Lei Geral de Proteção de Dados Pessoais – LGPD). Diário Oficial da União, 2018.

GIL, A. C. Como elaborar projetos de pesquisa. São Paulo: Atlas, 2002.

GOMAA, W. H.; FAHMY, A. A. A survey of text similarity approaches. International Journal of Computer Applications, v. 68, n. 13, p. 13–18, 2013.

Referências



INDYK, P.; MOTWANI, R. Approximate nearest neighbors: towards removing the curse of dimensionality. In: Proceedings of the Thirtieth Annual ACM Symposium on Theory of Computing. p. 604–613, 1998.

JURAFSKY, D.; MARTIN, J. H. Speech and Language Processing. 3. ed. Prentice Hall, 2023.

KARPUKHIN, V. et al. Dense passage retrieval for open-domain question answering. In: EMNLP, 2020. p. 6769–6781.

LAHITANI, A. R.; PERMANASARI, A. E.; SETIAWAN, N. A. Cosine similarity to determine similarity measure: Study case in online essay assessment. In: 2016 4th International Conference on Cyber and IT Service Management. IEEE, 2016. p. 1–6.

LEWIS, P. et al. Retrieval-augmented generation for knowledge-intensive NLP tasks. Advances in Neural Information Processing Systems, v. 33, p. 9459–9474, 2020.

MIKOLOV, T.; YIH, W.-t.; ZWEIG, G. Linguistic regularities in continuous space word representations. In: Proceedings of the 2013 Conference of the North American Chapter of the Association for Computational Linguistics: Human Language Technologies. 2013. p. 746–751.

MUJA, M.; LOWE, D. G. Fast approximate nearest neighbors with automatic algorithm configuration. In: VISAPP 2009 – International Conference on Computer Vision Theory and Applications. 2009. p. 331–340.

Referências



SILVEIRA JÚNIOR, C. A. C. Chatbot de perguntas e respostas para o Regimento Geral da UFPel utilizando ChatGPT e busca semântica. Dissertação (Mestrado) — Universidade Federal de Pelotas, 2023.

TURIAN, J.; RATINOV, L.; BENGIO, Y. Word representations: A simple and general method for semi-supervised learning. In: Proceedings of the 48th Annual Meeting of the Association for Computational Linguistics. 2010. p. 384–394.

TURING, A. M. Computing machinery and intelligence. In: Parsing the Turing Test: Philosophical and Methodological Issues in the Quest for the Thinking Computer. Springer, 2007. p. 23–65.

VASWANI, A. et al. Attention is all you need. Advances in Neural Information Processing Systems, v. 30, 2017.

WEIZENBAUM, J. ELIZA — A computer program for the study of natural language communication between man and machine. Communications of the ACM, v. 9, n. 1, p. 36–45, 1966.

WOHLIN, C. et al. Experimentation in software engineering. Springer, 2012.

ZHANG, T. et al. BERTScore: Evaluating text generation with BERT. In: International Conference on Learning Representations. 2019.



Agradecimentos

Armando Soares Sousa;

Disponível: <https://github.com/guilhermetorresm/tcc-chatbot-ufpi>

guilhermetorres@ufpi.edu.br

armando@ufpi.edu.br



Protótipo de Assistente Virtual Baseado em RAG para Consulta às Normas da UFPI: Um Estudo de Caso

Aluno: Guilherme Torres Melo
Orientador: Armando Soares Sousa

12 de Dezembro de 2025

Departamento de Computação – Universidade Federal do Piauí (UFPI) Teresina – PI – Brasil